哈尔滨工业大学 (深圳)

大数据实验指导书

实验二 数据理解、数据预处理及决策树的应用

1. 实验目的

- 1. 学会理解数据并对数据进行预处理;
- 2. 理解决策树的原理并掌握其构建方法。

2. 实验内容

- 1. 熟悉 Pandas 的安装和使用,并对数据进行预处理和可视化分析;
- 2. 熟悉 sklearn 包,调用决策树模型对数据进行训练。

3. 实验环境

- Jupyter
- PyCharm

4. 实验步骤

4.1 启动 jupyter

通过 cmd, 进入到实验二的目录下, 输入 jupyter lab 后, 会弹出 jupyter 的操作页面, 若未弹出则复制红框中的 url 到浏览器中。

4.2 安装 Pandas 库并熟悉其基本操作

Pandas 是 python 第三方库,提供高性能易用数据类型和分析工具。Pandas 基于 numpy 实现,常与 numpy 和 matplotlib 一同使用,更多学习请参考 pandas 中文网: https://www.pypandas.cn/。

4.2.1 安装 Pandas 库

打开 cmd 命令行窗口执行:

pip install pandas

4.2.2 Pandas 核心数据结构

维数	名称	描述
1	Series	带标签的一维同构数组
2	DataFrame	带标签的,大小可变的,二维异构表格

Series 是带标签的一维数组,可存储整数、浮点数、字符串、Python 对象等类型的数据。轴标签统称为索引。Series 中只允许存储相同的数据类型,这样可以更有效的使用内存,提高运算效率。调用 pd.Series 函数即可创建 Series。

DataFrame 是一个表格型的数据结构,类似于 Excel 或 sql 表,它含有一组有序的列,每列可以是不同的值类型 (数值、字符串、布尔值等)。DataFrame 既有行索引也有列索引,它可以被看做由 Series 组成的字典(共用同一个索引),可用多维数组字典、列表字典生成 DataFrame。

4.2.3 Pandas 库基本操作

(1) 生成数据

(2) 计算数据的基本信息

```
[7]: df.describe()

[7]: A B C

count 3.0 3.0 3.0

mean 2.0 5.0 8.0

std 1.0 1.0 1.0

min 1.0 4.0 7.0

25% 1.5 4.5 7.5

50% 2.0 5.0 8.0

75% 2.5 5.5 8.5

max 3.0 6.0 9.0
```

(3) 选取特定列

```
df[['A','C']]

A C

0 1 7

1 2 8

2 3 9
```

(4) 选取特定列行

```
df.iloc[[1,2]]

A B C

1 2 5 8

2 3 6 9
```

(5) 选取多行多列

```
df.iloc[[1,2],[0,2]]
A C
1 2 8
2 3 9
```

(6) 选取 B 列大于等于 5 的数据

```
df[df['B'] >= 5]

A B C

1 2 5 8

2 3 6 9
```

(7) 修改指定列

```
df['B'] = 0
print(df)

    A B C
0 1 0 7
1 2 0 8
2 3 0 9
```

4.3 数据读取及预处理

4.3.1 读取数据

(1) 读取 csv 文件并获取所有的表头

```
import numpy as np
import pandsa as pd
import pandsa as pd
import metplotib
import metplotib, pyplot as plt

df = pd.read_csv("D:/大师报/完全_/bank.csv")
cols = df.columns.values
cols = (col.replace('\"', '') for col in cols[0].split(';')]
print(cols)
['age', 'job', 'marital', 'education', 'default', 'balance', 'housing', 'loan', 'contact', 'day', 'month', 'duration', 'campaign', 'pdays', 'previous', 'poutcome', 'y']
```

属性	描述	类型	缺失值
age	年龄	数值	无
job	工作类型	分类	unknown
marital	婚姻状况	分类	无
education	受教育程度	分类	unknown
default	是否存在拖欠	分类	无
balance	平均年度余额 (欧元)	数值	无
housing	是否有住房贷款	分类	无
loan	是否有个人贷款	分类	无
contact	联络方式	分类	unknown
day	最后一次联系是几号	数值	无
month	最后一次联系的月份	分类	无
duration	最后一次联系的持续时间(秒)	数值	无

属性	描述	类型	缺失值
campaign	此营销活动期间和此客户联系的次数, 包括最后一次联系	数值	无
pdays	从上一个营销活动最后一次联系客户 后经过的天数,-1表示之前未联系过 客户	数值	无
previous	此营销活动之前和此客户联系的次数	数值	无
poutcome	上一次营销活动的结果	分类	unknown
у	客户是否将订购银行定期存款	分类	无

(2) 获取所有的数据并转为二维数组的形式

```
datas = []
for i in range(len(df)):
    s = df.iloc[i].values[0]
    datas.append([item.replace('\"', '') for item in s.split(';')])

datas = np.array(datas)
print(datas)

[['30' 'unemployed' 'married' ... '0' 'unknown' 'no']
    ['33' 'services' 'married' ... '4' 'failure' 'no']
    ['35' 'management' 'single' ... '1' 'failure' 'no']
    ...
    ['57' 'technician' 'married' ... '0' 'unknown' 'no']
    ['28' 'blue-collar' 'married' ... '3' 'other' 'no']
    ['44' 'entrepreneur' 'single' ... '7' 'other' 'no']]
```

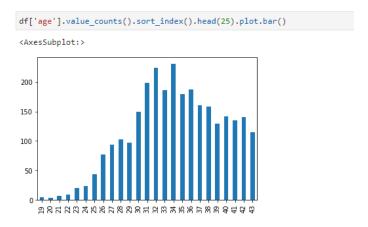
(3) 将数据与表头转化为 DataFrame 格式

(4) 将以下列从字符类型转为整数类型

```
df[['age','balance','duration', 'campaign','pdays','previous']] = df[['age','balance','duration', 'campaign','pdays','previous']].astype(int)
age
job
marital
education
default
                  int32
                  int32
balance
housing
                 object
                 object
object
object
object
int32
loan
 contact
day
month
duration
                  int32
campaign
pdays
                  int32
 previous
                  int32
poutcome object
y object
Length: 17, dtype: object
```

(5) 数据可视化

绘制柱状图:



绘制折线图:

```
df['age'].value_counts().sort_index().plot.line()

<matplotlib.axes._subplots.AxesSubplot at 0x247287b8be0>

200

150

200

30

40

50

60

70

80
```

4.3.2 数据预处理

(1) 筛选重复值并删除

df.duplicated()			op_du	plicates()															
			age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	,
0	False	0	30	unemployed	married	primary	no	1787	no	no	cellular	19	oct	79	1	-1	0	unknown	no
1	False	1	33	services	married	secondary	no	4789	yes	yes	cellular	11	may	220	1	339	4	failure	no
3	False False	2	35	management	single	tertiary	no	1350	yes	no	cellular	16	apr	185	1	330	1	failure	no
4	False	3	30	management	married	tertiary	no	1476	yes	yes	unknown	3	jun	199	4	-1	0	unknown	no
-		4	59	blue-collar	married	secondary	no	0	yes	no	unknown	5	may	226	1	-1	0	unknown	no
4516	False																		
4517	False	4516	33	services	married	secondary	no	-333	yes	no	cellular	30	jul	329	5	-1	0	unknown	no
4518	False	4517	57	self-employed	married	tertiary	yes	-3313	yes	yes	unknown	9	may	153	1	-1	0	unknown	no
4519	False	4518	57	technician	married	secondary	no	295	no	no	cellular	19	aug	151	11	-1	0	unknown	no
4520	False	4519	28	blue-collar	married	secondary	no	1137	no	no	cellular	6	feb	129	4	211	3	other	no
Length:	4521, dtype: bool	4520	44	entrepreneur	single	tertiary	no	1136	yes	yes	cellular	3	apr	345	2	249	7	other	no

(2) 将 yes/no 分类映射为 0/1 分类

```
class_mapping = {'no':0, 'yes':1}
df['default'] = df['default'].map(class_mapping)
df['housing'] = df['housing'].map(class_mapping)
df['loan'] = df['loan'].map(class_mapping)
df['y'] = df['y'].map(class_mapping)
```

	у	default	housing	loan
)	no	no	no	no
1	no	no	yes	yes
2	no	no	yes	no
3	no	no	yes	yes
4	no	no	yes	no
6	no	no	yes	no
7	no	yes	yes	yes
8	no	no	no	no
19	no	no	no	no
0	no	no	yes	yes

(3) 将月份和日期转化成距离现在的天数

(4) 删除原有的月份与日期

```
del(df['day'])
del(df['month'])
```

(5) 将字符型分类变量转化为数值型并处理缺失值

```
jobs = df['job'].unique()
job_mapping = {jobs[i]: i for i in range(jobs.shape[0])}
maritals = df['marital'].unique()
maritals_mapping = {maritals[i]: i for i in range(maritals.shape[0])}
educations = df['education'].unique()
education_mapping = {educations[i]: i for i in range(educations.shape[0])}

contacts = df['contact'].unique()
contact_mapping = {contacts[i]: i for i in range(contacts.shape[0])}

poutcomes = df['poutcome'].unique()
poutcome_mapping = {poutcomes[i]: i for i in range(poutcomes.shape[0])}

df['marital'] = df['marital'].map(marital_mapping)
df['job'] = df['job'].map(job_mapping)
df['contact'] = df['dducation'].map(education_mapping)
df['contact'] = df['contact'].map(contact_mapping)
df['poutcome'] = df['poutcome'].map(poutcome_mapping)
df
df['poutcome'] = df['poutcome'].map(poutcome_mapping)
df
```

1:		age	job	marital	education	default	balance	housing	loan	contact	duration	campaign	pdays	previous	poutcome	у	date
	0	30	0	0	0	0	1787	0	0	0	79	1	-1	0	0	0	74
	1	33	1	0	1	0	4789	1	- 1	0	220	1	339	4	1	0	235
	2	35	2	1	2	0	1350	1	0	0	185	1	330	1	1	0	260
	3	30	2	0	2	0	1476	1	1	1	199	4	-1	0	0	0	212
	4	59	3	0	1	0	0	1	0	1	226	1	-1	0	0	0	241
											***			***			
	4516	33	1	0	1	0	-333	1	0	0	329	5	-1	0	0	0	155
	4517	57	4	0	2	1	-3313	1	1	1	153	1	-1	0	0	0	237
	4518	57	5	0	1	0	295	0	0	0	151	11	-1	0	0	0	135
	4519	28	3	0	1	0	1137	0	0	0	129	4	211	3	2	0	329
	4520	44	6	1	2	0	1136	1	1	0	345	2	249	7	2	0	273

4521 rows × 16 columns

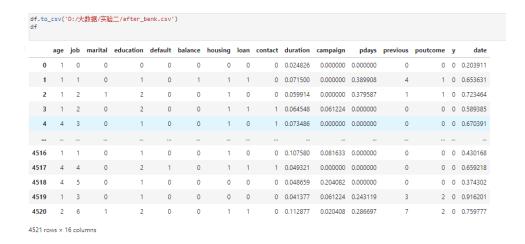
(6) 将以下两列的数据离散化

分箱:

```
bins = [18, 25, 35, 45, 55, 100] # 指定年龄的分界点
df['age'] = pd.cut(df['age'], bins, labels=False)
bins = [-np.inf, 4137.1, 11587.2, np.inf]
df['balance'] = pd.cut(df['balance'], bins, labels=False)
print(df[['age','balance']])
       age balance
0
        1
                  0
1
        1
                  1
2
        1
                  0
3
        1
                  0
4
        4
                  0
4516
                0
        1
                0
0
4517
        4
4518
        4
4519
        1
                 0
4520
        2
                  0
```

(7) 将以下四列的数据归一化

(8) 保存数据



4.4 安装 sklearn 并构建决策树

决策树是一种树形结构的分类器,通过顺序询问分类点的属性决定分类点最终类别。通常根据特征的信息增益或其他指标,构建一棵决策树。

4.4.1 安装 sklearn

D:\大数据\实验二>pip install scikit-learn

4.4.2 读取数据

```
from sklearn.tree import DecisionTreeClassifier as DTC, export_graphviz # 读取数据

df = pd.read_csv('D:/大数据/实验二/after_bank.csv')

df = df.iloc[:,1:]
cols = list(df.columns.values)
cols.remove('y')

X = df[cols]
y = df[['y']]
```

4.4.3 划分训练集和测试集

```
# 划分训练集与测试集

X_train = X[:4000]

y_train = y[:4000]

X_test = X[4000:5000]

y_test = y[4000:5000]
```

4.4.4 训练模型

```
dtc = DTC(criterion='entropy', max_depth=5) # 基于信息熵
dtc.fit(X_train, y_train)
print('准确率: ', dtc.score(X_test, y_test))

准确率: 0.8886756238003839
```

4.4.5 参数调整

构建模型中很重要的一步是<mark>调参</mark>。在 sklearn 中, 模型的参数是通过方法参数来决定的, 以下给出 sklearn 中, 决策树的参数:

通常来说,较为重要的参数有:

criterion: 用以设置用信息熵还是基尼系数计算

string, optional (default="gini")

- (1).criterion='gini',分裂节点时评价准则是 Gini 指数。
- (2).criterion='entropy',分裂节点时的评价指标是信息增益。

splitter: 指定分支模式

string, optional (default="best")。指定分裂节点时的策略。

- (1).splitter='best',表示选择最优的分裂策略。
- (2).splitter='random',表示选择最好的随机切分策略。

max_depth: 最大深度, 防止过拟合

int or None, optional (default=None)。指定树的最大深度。

如果为 None,表示树的深度不限。直到所有的叶子节点都是纯净的,即叶子节点中所有的样本点都属于同一个类别。或者每个叶子节点包含的样本数小于 min_samples_split。

min_samples_leaf: 限定每个节点分枝后子节点至少有多少个数据, 否则就不分枝 int, float, optional (default=2)。表示分裂一个内部节点需要的做少样本数。

- (1).如果为整数,则 min_samples_split 就是最少样本数。
- (2).如果为浮点数(0到1之间),则每次分裂最少样本数为 ceil(min_samples_split * n_samples)

(1) 采用基尼系数替换信息熵对结果的影响:

```
dtc = DTC(criterion='gini', max_depth=5) # 基于基尼系数
dtc.fit(X_train, y_train)
print('准确率: ', dtc.score(X_test, y_test))

准确率: 0.8925143953934741
```

(2) 采用不同的树的深度,对结果的影响

```
for depth in range(1, 10):
    dtc = DTC(criterion='entropy', max_depth=depth) # 基于信息簿
    dtc.fit(X_train, y_train)
    print('depth:', depth, '|', '准确率:', dtc.score(X_test, y_test))

depth: 1 | 准确率: 0.8790786948176583
depth: 2 | 准确率: 0.8733205374280231
depth: 3 | 准确率: 0.8963531669865643
depth: 4 | 准确率: 0.9001919385796545
depth: 5 | 准确率: 0.9001919385796545
depth: 6 | 准确率: 0.8905950095969289
depth: 7 | 准确率: 0.8905950095969289
depth: 8 | 准确率: 0.8867562380038387
depth: 9 | 准确率: 0.8848368522072937
```

4.4.5 可视化决策树模型

(1) 安装 Graphviz

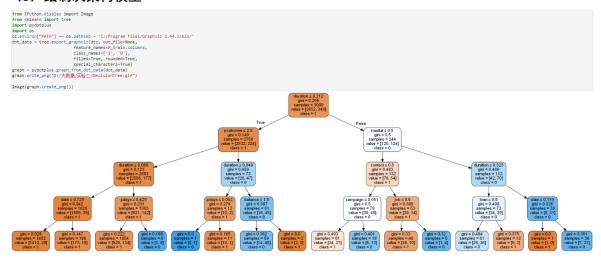
下载 graphviz-install-2.44.1-win64.exe 并安装,下载地址:

https://www2.graphviz.org/Packages/stable/windows/10/cmake/Release/x64/

(2) 安装 pydotplus

pip install pydotplus

(3) 绘制决策树模型



绘制决策树时, 如果遇到:

InvocationException: Program terminated with status: 1. stderr follows: Format: "png" not re cognized. Use one of:

可用管理员身份运行 cmd, 执行

C:\Windows\system32>cd c:/ c:\>cd Program Files\Graphviz 2.44.1\bin c:\Program Files\Graphviz 2.44.1\bin>dot -c c:\Program Files\Graphviz 2.44.1\bin>_